

Entrega 3 - Diseño del modelo de datos y capa gold del proyecto

Enunciado de la tercera entrega incremental del proyecto.

Contexto de la entrega

En la entrega anterior seleccionasteis la idea de proyecto con la que vais a trabajar durante el curso y analizasteis qué datos necesitáis, de dónde los vais a obtener y qué riesgos iniciales existen respecto a disponibilidad, calidad, privacidad y estabilidad de las fuentes.

En esta tercera entrega debéis avanzar hacia el diseño del sistema de datos del proyecto. El objetivo no es todavía construir toda la solución final, sino definir con claridad cómo vais a organizar, almacenar y estructurar los datos para que puedan ser utilizados de forma consistente en las siguientes fases del proyecto: análisis, modelado, visualización y presentación de resultados.

Un proyecto de Data Science no puede depender de ficheros sueltos, columnas ambiguas o transformaciones improvisadas. Antes de modelar o visualizar, debe existir una estructura clara de datos y una definición mínima del contrato de datos que vais a consumir.

Objetivo

El objetivo de esta entrega es definir el modelo de datos que vais a utilizar en vuestro proyecto. Debéis especificar qué tecnología o formato vais a utilizar para almacenar y trabajar los datos, cómo se estructurarán las distintas capas de información y, especialmente, cuál será vuestra capa final o capa gold, entendida como el conjunto de datos limpios, definidos y preparados que se utilizarán en las fases posteriores del proyecto.

Estructura obligatoria del repositorio

```
docs/  
  -- entregas/  
    -- 01_ideas_producto.md  
    -- 02_datos_necesarios.md  
    -- 03_modelo_datos.md
```

En esta entrega espero encontrar, como mínimo, los siguientes ficheros dentro de docs/entregas/:

- **01_ideas_producto.md**: debe contener el resultado de la entrega 1, con las ideas de producto planteadas inicialmente.
- **02_datos_necesarios.md**: debe contener el resultado de la entrega 2, con la idea seleccionada, el análisis de datos necesarios, fuentes previstas, privacidad y viabilidad inicial.
- **03_modelo_datos.md**: debe contener el desarrollo completo de esta entrega 3.

La entrega debe ser incremental. No debéis borrar ni sustituir las entregas anteriores. El objetivo es mantener la trazabilidad completa de la evolución del proyecto.

Contenido del fichero 03_modelo_datos.md

1. Resumen de la idea y datos del proyecto

Incluid una breve síntesis de la idea seleccionada y de los datos principales que vais a utilizar. No se trata de repetir toda la entrega anterior, sino de recordar brevemente:

- Qué problema resuelve el proyecto.
- Qué solución queréis construir.
- Qué fuentes de datos vais a utilizar.
- Qué tipo de información aportará cada fuente.

2. Tecnología o formato de almacenamiento elegido

Explicad cómo vais a almacenar y organizar los datos del proyecto. Para cada elección, justificad por qué tiene sentido en vuestro proyecto. No se valorará utilizar una tecnología más compleja porque sí, sino escoger una opción coherente con el tipo de datos, el volumen, la estructura del proyecto y el nivel de desarrollo esperado durante el curso.

- Ficheros CSV.
- Ficheros Excel.
- Ficheros JSON.
- Ficheros Parquet.
- Base de datos relacional, como SQLite, PostgreSQL, MySQL u otra.
- Una combinación de varios formatos.

3. Estructura de capas de datos

Definid cómo vais a organizar los datos a lo largo del proyecto. Como mínimo, debéis explicar si vais a trabajar con una estructura similar a:

```
data/
|-- raw/
|-- processed/
`-- gold/
```

Capa	Contenido esperado
Raw	Datos originales, tal y como se obtienen de la fuente, sin modificaciones o con las mínimas transformaciones necesarias para poder guardarlos.
Processed	Datos limpios o parcialmente transformados, con tratamiento de errores, tipos de datos, duplicados, formatos de fecha, nombres de columnas u otras transformaciones intermedias.
Gold	Datos finales preparados para ser consumidos en análisis, modelos, dashboards o entregables finales.

Si vuestro proyecto necesita otra estructura, podéis proponerla, pero debe estar justificada.

4. Definición de la capa gold

Esta es la parte más importante de la entrega. Debéis definir cuál será vuestra capa gold: qué tabla, fichero, vista o conjunto de datasets será el resultado final de preparación de datos y servirá como entrada para las siguientes fases del proyecto.

Para cada tabla o dataset de la capa gold, indicad:

- Nombre del fichero, tabla o dataset.
- Descripción funcional.
- Nivel de granularidad.
- Número aproximado esperado de registros.
- Campos principales.
- Tipo de dato esperado para cada campo.
- Clave primaria o identificador principal, si aplica.
- Variables objetivo, métricas o columnas especialmente relevantes para el análisis o modelo.
- Qué fase posterior consumirá ese dataset: EDA, modelo, dashboard, informe, aplicación, etc.

Dataset gold	Granularidad	Campos clave	Uso posterior
gold_XXX.csv	Una fila por...	id, fecha, variable_1, variable_2	Modelo predictivo / dashboard / análisis

5. Relaciones entre datos

Si vuestro proyecto utiliza más de una tabla, fuente o dataset, debéis explicar cómo se relacionan entre sí. Indicad:

- Qué tablas o datasets existen.

- Qué claves permiten relacionarlos.
- Si existen relaciones 1:1, 1:N o N:M.
- Si será necesario hacer joins, agregaciones o cruces de datos.
- Qué problemas pueden aparecer al combinar fuentes diferentes.
- Si vuestro proyecto solo utiliza un único dataset, indicadlo explícitamente y justificad por qué no necesitáis un modelo relacional más complejo.

```
clientes.id_cliente 1 --- N ventas.id_cliente
productos.id_producto 1 --- N ventas.id_producto
```

6. Diccionario de datos inicial

Incluid un primer diccionario de datos de los campos principales que vais a utilizar. No hace falta documentar absolutamente todas las columnas si el dataset es muy grande, pero sí aquellas que sean relevantes para el análisis, el modelo o el dashboard final.

Campo	Descripción	Tipo de dato	Fuente	Obligatorio	Observaciones
fecha	Fecha del registro	date	Fuente X	Sí	Formato esperado: YYYY-MM-DD
precio	Precio del producto	float	Fuente Y	Sí	Puede requerir limpieza de moneda

7. Problemas de calidad esperados

Identificad los principales problemas de calidad que creéis que pueden aparecer en vuestros datos. No basta con listar problemas genéricos. Debéis aterrizarlos a vuestro caso concreto. Debéis analizar, cuando aplique:

- Valores nulos.
- Duplicados.
- Inconsistencia en nombres o categorías.
- Fechas mal formateadas.
- Unidades de medida distintas.
- Cambios de definición entre fuentes.
- Datos desactualizados.
- Falta de histórico suficiente.
- Sesgos de cobertura.
- Datos extremos u outliers.
- Problemas al cruzar fuentes.
- Campos relevantes que no estén disponibles.

8. Decisiones de limpieza y transformación previstas

Explicad qué decisiones iniciales tomaréis para preparar los datos. Estas decisiones pueden cambiar más adelante, pero en esta entrega deben quedar definidas las hipótesis iniciales. Por ejemplo:

- Cómo trataréis valores nulos.
- Cómo eliminaréis o gestionaréis duplicados.
- Cómo normalizaréis fechas, textos, categorías o unidades.
- Qué variables derivadas pensáis construir.
- Qué agregaciones serán necesarias.
- Qué datos se descartarán y por qué.
- Qué criterios usaréis para considerar que un registro es válido o inválido.

9. Riesgos del modelo de datos

Cerrad el documento con una valoración breve de los riesgos principales del modelo de datos. Debéis responder:

- ¿Qué parte del modelo de datos está más clara?
- ¿Qué parte genera más incertidumbre?
- ¿Qué fuente o tabla puede dar más problemas?
- ¿Qué ocurriría si no podéis construir la capa gold tal como la habéis definido?
- ¿Qué alternativa tendríais para simplificar el modelo si fuera necesario?

Criterios de corrección

Criterio	Qué se valorará
Coherencia tecnológica	La elección de CSV, Parquet, base de datos relacional u otra tecnología debe estar justificada y ser adecuada al proyecto.
Claridad de la estructura de datos	Debe entenderse cómo se organizarán los datos desde la fuente original hasta el dataset final de trabajo.
Definición de la capa gold	La capa gold debe estar claramente descrita y debe servir como contrato de datos para las fases posteriores del proyecto.
Definición de campos y granularidad	Se valorará que el equipo especifique correctamente qué representa cada fila, qué campos son relevantes y qué tipos de datos se esperan.
Relaciones entre datos	Si existen varias fuentes o tablas, las relaciones entre ellas deben estar bien explicadas. Si no existen, debe justificarse.
Problemas de calidad	Se valorará que el equipo anticipe problemas reales y concretos de calidad de datos, no solo una lista genérica.
Limpieza y transformación	Las decisiones previstas deben ser razonables, trazables y coherentes con el objetivo del proyecto.
Realismo del diseño	El modelo de datos debe poder construirse de forma realista durante el curso, sin depender de una arquitectura excesivamente compleja o inviable.
Trazabilidad del trabajo	El repositorio debe incluir los ficheros correspondientes a las entregas 1, 2 y 3 dentro de docs/entregas/.

Resultado esperado

Al finalizar esta entrega, el repositorio debe permitir entender:

- Qué datos usará el proyecto.
- Cómo se almacenarán.
- Qué estructura de capas tendrá el proyecto.
- Qué dataset o datasets formarán la capa gold.
- Qué campos principales se utilizarán.
- Qué relaciones existen entre los datos.
- Qué problemas de calidad se esperan.
- Qué transformaciones iniciales serán necesarias.
- Qué riesgos existen en el diseño del modelo de datos.